

タイトル: 大規模高次元ベクトル空間における近似最近傍探索

著者: Daniel K. Okafor (オックスフォード大学 計算機科学科)

概要

近似最近傍探索は、セマンティック検索エンジンからレコメンデーションプラットフォームまで、現代の検索システムを支えている。本論文は、グラフベース、木構造ベース、量子化ベースの各インデックス手法を数十億規模のベクトルデータセット上で比較し、再現率、レイテンシ、メモリ使用量のトレードオフを評価する。

1. はじめに

埋め込みの次元数とデータセット規模が増大するにつれて、厳密な最近傍探索は計算上実行不可能になる。近似手法はわずかな精度をクエリ速度の大幅な向上と引き換えにするが、最適な手法はデータ分布とハードウェア制約に大きく依存する。

2. 比較した手法

本研究では、階層的ナビゲーション可能スモールワールドグラフ、プロダクト量子化を用いた転置ファイルインデックス、ランダム化KD木フォレストを、1000万から10億の768次元ベクトルを持つ3種類のデータセットにわたってベンチマークする。

3. 結果

グラフベース手法は、1億ベクトル未満のデータセットにおいて所定のレイテンシ予算のもとで最も高い再現率を達成するが、メモリを大幅に多く要する。量子化ベース手法は10億ベクトル規模のデータセットにより滑らかにスケールし、約4パーセントの再現率を犠牲にすることでメモリ使用量を6分の1に削減する。

4. 議論

すべての運用点で唯一支配的な手法は存在しない。多様なワークロードを扱うシステムは、レイテンシとメモリ予算に基づいてクエリを異なるインデックス種別へ振り分けるハイブリッドアーキテクチャから利益を得られる可能性がある。

5. 結論

大規模ベクトル検索におけるインデックス選定は、固定的なアーキテクチャの選択としてではなく、再現率・レイテンシ・インフラコストにわたる同時最適化問題として扱うべきである。